

Java Web Scraper

PLAN ROZWOJU PROJEKTU (ROADMAP OD MVP DO SYSTEMU PRODUKCYJNEGO)

Poniższy dokument stanowi ustrukturyzowany przewodnik rozwoju Twojej aplikacji do scrapowania cen z serwisu Amazon. Został przygotowany z myślą o programiście ze znajomością JavaScript/Node.js, minimalizując niepotrzebny narzut konfiguracyjny na start i skupiając się na kluczowych mechanizmach języka Java.

1. Rekomendacja Bazy Danych na start

Przejsie z zapisów plikowych na bazę danych wymaga wyboru odpowiedniego silnika. Oto dwie rekomendowane ścieżki:

Opcja A (Rekomendowana): H2 Database (In-Memory / File)

Baza danych napisana w czystej Javie. Działa bezpośrednio w pamięci aplikacji lub jako lokalny plik, bez konieczności instalowania zewnętrznych serwerów czy kontenerów Docker. Pozwala na naukę standardów branżowych Javy (JPA/Hibernate) w całkowicie bezobsługowym środowisku.

Opcja B: MongoDB

Jeśli chcesz zobaczyć, jak sztywno typowana Java radzi sobie z dynamicznymi dokumentami NoSQL (BSON/JSON), to świetny poligon doświadczalny. Przydatne, jeśli znasz już ten stos z ekosystemu Node.js.

2. Kamienie Milowe Rozwoju Aplikacji

KROK 1

Integracja z DB (H2) i Historia Cen

Zastąpienie dotychczasowego zapisu do pliku tekstowego/CSV relacyjną bazą danych w celu gromadzenia ustrukturyzowanych danych historycznych.

- **Logika działania:** Każde uruchomienie programu pobiera cenę i zapisuje nowy wiersz w tabeli historycznej wraz ze znacznikiem czasu (timestamp).
- **Czego się nauczysz:** Podstaw korzystania z JDBC lub Spring Data JPA. Mapowania klas Javy na tabele bazodanowe (konceptcja ORM).

H2 Database

Spring Data JPA / Hibernate

KROK 2

Automatyzacja i Praca w Tle (Scheduler)

Eliminacja konieczności ręcznego uruchamiania aplikacji w celu sprawdzenia aktualnych cen.

- **Logika działania:** Aplikacja działa nieprzerwanie jako proces w tle. Wbudowany mechanizm harmonogramu wywołuje metodę scrapującą w zdefiniowanych odstępach czasu (np. raz na dobę lub co godzinę).
- **Czego się nauczysz:** Obsługi zadań cyklicznych w Javie. Porównasz to z mechanizmem ``cron`` lub ``setInterval`` z Node.js.

@Scheduled (Spring)

TaskScheduler

KROK 3

Obsługa Wielu Produktów ("Lista Życzeń")

Przejdzie od pojedynczego, zahardkodowanego adresu URL do elastycznego zarządzania wieloma produktami jednocześnie.

- **Logika działania:** Tworzone są dwie powiązane tabele: ``Product`` (zawierająca URL, nazwę i cenę docelową) oraz ``PriceHistory``. Program najpierw pobiera listę wszystkich aktywnych produktów z bazy, a następnie w pętli przetwarza każdy z nich.
- **Czego się nauczysz:** Relacji bazodanowych (One-To-Many), dynamicznego zarządzania kolekcjami (``List``, ``Map``) oraz czyszczenia danych dla różnych struktur HTML.

Relacje JPA

Java Collections Framework

KROK 4

System Alertyzacji (Zewnętrzne powiadomienia)

Wyjście poza komunikaty w terminalu. System aktywnie informuje użytkownika o okazjach cenowych.

- **Logika działania:** Po zapisaniu ceny program sprawdza warunek: czy obecna cena jest niższa niż ``target_price`` zdefiniowana dla produktu. Jeśli tak, aplikacja wysyła powiadomienie poprzez zewnętrzne API.
- **Czego się nauczysz:** Integracji z zewnętrznymi usługami REST API z poziomu Javy (wysyłanie żądań POST), obsługi bibliotek klienckich.

Discord/Telegram Webhooks

Java HttpClient / RestTemplate

KROK 5

Wielowątkowość i Asynchroniczność (Concurrency)

Optymalizacja wydajnościowa aplikacji przy dużej liczbie monitorowanych produktów.

- **Logika działania:** Zamiast pobierać i parsować strony sekwencyjnie (jedna po drugiej), zadania pobierania przydzielane są do puli wątków. Wiele stron pobiera się w tym samym ułamku sekundy.
- **Czego się nauczysz:** Prawdziwej wielowątkowości Javy. Zrozumiesz różnicę między pętlą zdarzeń (Event Loop) z JavaScriptu a natywnym zarządzaniem wątkami procesora w maszynie JVM.

ExecutorService

CompletableFuture

Thread Pool

3. Strategiczna wskazówka architektoniczna

Rekomendacja technologiczna: Najlepszym momentem na wdrożenie frameworka **Spring Boot** jest **Krok 1**.

Spring Boot automatycznie skonfiguruje bazę danych H2, udostępni adnotacje do harmonogramów (`@Scheduled`) oraz dostarczy gotowe narzędzia do wysyłania powiadomień HTTP. Pozwoli Ci to pominąć pisanie powtarzalnego kodu (boilerplate) i skupić się na czystej logice biznesowej.